

# Analyse en composante principales

Mathématique

---

Véronique Tremblay

# L'idée de l'ACP

---

On cherche une combinaison linéaire des variables qui maximise la variance.

$$Y = aX_1 + bX_2 + cX_3 + \dots$$



$p$ : le nombre de variables

$n$ : le nombre d'observations

$X$ : une matrice  $n \times p$  qui contient les données

$\Sigma$ : la matrice de variance-covariance de  $X$

$Y_k$ : la  $k^e$  composance principale

$\alpha_k$ : les coefficients permettant d'obtenir la  $k^e$  composante

$$\begin{aligned} Y_k &= \alpha_{k,1}X_1 + \alpha_{k,2}X_2 + \dots \\ &= \alpha_k^\top X \end{aligned}$$

# Trouver la première composante principale

---

On veut trouver une première composante principale qui maximise

$$\text{Var}(Y_1) = \text{Var}(\alpha_k^\top X)$$

## Trouver la première composante principale

---

- Le problème est donc de maximiser

$$F(\alpha_1) = \alpha_1^\top \Sigma \alpha_1$$

- Sous la contrainte que  $\alpha_1^\top \alpha_1 = 1$ .

$$F(\alpha_1, \lambda) = \alpha_1^\top \Sigma \alpha_1 - \lambda(\alpha_1^\top \alpha_1 - 1)$$

## Trouver la première composante principale

---

On dérive, on pose la dérivée à zéro et on obtient:

$$2\Sigma\alpha_1 - 2\lambda\alpha_1 = 0$$

Qui est vrai seulement si:

$$\Sigma\alpha_1 = \lambda\alpha_1$$

Soit  $M$  une matrice carrée. Alors on dit que  $\lambda$  est une *valeur propre* de  $M$  s'il existe un vecteur  $\mathbf{x} \neq \mathbf{0}$  tel que

$$M\mathbf{x} = \lambda\mathbf{x}.$$

Le vecteur  $\mathbf{x}$  est appelé *vecteur propre* correspondant à la valeur propre  $\lambda$  et l'ensemble des nombres réels  $\lambda$  satisfaisant l'équation précédente est appelé *spectre* de la matrice  $M$ .

## Trouver la première composante principale

---

$$\Sigma \alpha_1 = \lambda \alpha_1$$

On en déduit que:

1.  $\alpha_1$  est un vecteur propre (normé) de  $\Sigma$ ;
2.  $\lambda$  est la valeur propre correspondante.



## Trouver la première composante principale

---

Calculons la variance de  $Y_1$ .

$$\begin{aligned}\mathbb{V}\text{ar}(Y_1) &= \alpha_1^\top \Sigma \alpha_1 \\ &= \lambda \alpha_1^\top \alpha_1 \\ &= \lambda.\end{aligned}$$

## Trouver la première composante principale

---

On conclut que

1.  $\lambda = \lambda_1$  est **la plus grande valeur propre de  $\Sigma$** ;
2.  $\alpha_1$  est le vecteur propre normé correspondant.

## Trouver la deuxième composante principale

---

On poursuit simultanément deux objectifs:

1. conserver le **maximum de variation** présente dans **X**
2. simplifier la structure de dépendance pour - faciliter l'interprétation - assurer la stabilité numériques des méthodes qui utiliseront les composantes principales obtenues

## Trouver la deuxième composante principale

---

Étant donné  $Y_1$ , la deuxième composante principale

$$Y_2 = \alpha_2^\top X$$

est définie telle que:

1.  $\text{Var}(Y_2) = \alpha_2^\top \Sigma \alpha_2$  est maximale
2.  $\alpha_2^\top \alpha_2 = 1$
3.  $\text{cov}(Y_1, Y_2) = 0$

## Trouver toutes les composantes principales

---

Quelques calculs permettent de conclure que:

$$Y_k = \alpha_k^\top X$$

où  $\alpha_k$  est le vecteur propre normé associé à  $\lambda_k$ , la  $k^{\text{e}}$  plus grande valeur propre de  $\Sigma$ .

$$\mathbf{Y} = \mathbf{XA}$$
$$\begin{pmatrix} y_{11} & y_{12} & \cdots & y_{1p} \\ y_{21} & y_{22} & \cdots & y_{2p} \\ \vdots & \vdots & \vdots & \vdots \\ y_{n1} & y_{n2} & \cdots & y_{np} \end{pmatrix} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \vdots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix} \begin{pmatrix} \alpha_{11} & \alpha_{21} & \cdots & \alpha_{p1} \\ \alpha_{12} & \alpha_{22} & \cdots & \alpha_{p2} \\ \vdots & \vdots & \vdots & \vdots \\ \alpha_{1p} & \alpha_{2p} & \cdots & \alpha_{pp} \end{pmatrix}$$

## Rappel d'algèbre

- Si  $\alpha$  est un vecteur propre de  $\Sigma$  correspondant à une valeur propre  $\lambda$ , alors  $c\alpha$  sera également un vecteur propre de  $\Sigma$  correspondant à  $\lambda$ .
- Si  $\Sigma$  est symétrique et  $\alpha_1$  et  $\alpha_2$  sont des vecteurs propres correspondant à des valeurs propres différentes de  $\Sigma$ , alors  $\alpha_1$  et  $\alpha_2$  sont orthogonaux, i.e.,  $\alpha_1^\top \alpha_2 = 0$ .
- Si  $\Sigma$  est symétrique, toutes ses valeurs propres sont réelles.
- Si  $\Sigma$  est définie non-négative [définie positive] alors toutes ses valeurs propres sont non-négatives [positives].