

# **Modèles de mélange de densités**

Algorithme EM pour un mélange de deux gaussienne

---

Véronique Tremblay

Voir la section 8.5.1 du livre Elements of Statistical Learning (Hastie, Tibshirani, and Friedman (2009)).


Solutions aux défis de la  $\ell\ell$  du modèle de mélanges :

$$\ell(\theta; Y) = \sum_{j=1}^n \log \left[ \sum_{i=1}^K \pi_i f_i(Y_j, \theta_i) \right]$$

- Approche générique d'estimation de modèles paramétriques lorsque la vraisemblance est difficile à manipuler (Dempster, Laird, and Rubin (1977))
- Tire son nom des deux étapes:
  - $E$  = expectation
  - $M$  = maximization

## Exemple pour 2 gaussiennes

$$\ell(\theta|Y) = \sum_{j=1}^n \log [\pi_1 \phi_{\theta_1}(Y_j) + \pi_2 \phi_{\theta_2}(Y_j)]$$




## Étape 1: initialisation

$$\mu_1^{(0)} = 223$$

$$\mu_2^{(0)} = 254$$

$$\sigma_1^2 = \sigma_2^2 = 19$$

$$\pi^{(0)} = 0.5$$




Distributions initiales

## Itération 1

---

## Étape 2 : Expectation

$$\hat{\gamma}_i^{(0)} = \frac{\pi_2^{(0)} \phi_2^{(0)}(y_i)}{\pi_1^{(0)} \phi_1^{(0)}(y_i) + \pi_2^{(0)} \phi_2^{(0)}(y_i)}$$



Distributions initiales



## Étape 3: Maximisation


$$\hat{\mu}_1^{(1)} = \frac{\sum_{i=1}^N (1 - \hat{\gamma}_i^{(0)}) y_i}{\sum_{i=1}^N (1 - \hat{\gamma}_i^{(0)})} = 227$$

$$\hat{\mu}_2^{(1)} = \frac{\sum_{i=1}^N (\hat{\gamma}_i^{(0)}) y_i}{\sum_{i=1}^N (\hat{\gamma}_i^{(0)})} = 250$$

$$\hat{\sigma}_1^{2(1)} = \frac{\sum_{i=1}^N (1 - \hat{\gamma}_i^{(0)}) (y_i - \hat{\mu}_1^{(1)})^2}{\sum_{i=1}^N (1 - \hat{\gamma}_i^{(0)})} = 243$$

$$\hat{\sigma}_2^{2(1)} = \frac{\sum_{i=1}^N (\hat{\gamma}_i^{(0)}) (y_i - \hat{\mu}_2^{(1)})^2}{\sum_{i=1}^N (\hat{\gamma}_i^{(0)})} = 219$$

$$\hat{\pi}^{(1)} = 0.5$$




Distributions à la fin de l'itération 1

## Itération 2

---

## Étape 2: Expectation

$$\hat{\gamma}_i^{(1)} = \frac{\pi_2^{(1)} \phi_2^{(1)}(y_i)}{\pi_1^{(1)} \phi_1^{(1)}(y_i) + \pi_2^{(1)} \phi_2^{(1)}(y_i)}$$



Distributions à la fin de l'itération 1

## Étape 3: Maximisation


$$\hat{\mu}_1^{(2)} = \frac{\sum_{i=1}^N (1 - \hat{\gamma}_i^{(1)}) y_i}{\sum_{i=1}^N (1 - \hat{\gamma}_i^{(1)})} = 226$$

$$\hat{\mu}_2^{(2)} = \frac{\sum_{i=1}^N (\hat{\gamma}_i^{(1)}) y_i}{\sum_{i=1}^N (\hat{\gamma}_i^{(1)})} = 250$$

$$\hat{\sigma}_1^{2(1)} = \frac{\sum_{i=1}^N (1 - \hat{\gamma}_i^{(1)}) (y_i - \hat{\mu}_1^{(2)})^2}{\sum_{i=1}^N (1 - \hat{\gamma}_i^{(1)})} = 226$$

$$\hat{\sigma}_2^{2(2)} = \frac{\sum_{i=1}^N (\hat{\gamma}_i^{(1)}) (y_i - \hat{\mu}_2^{(2)})^2}{\sum_{i=1}^N (\hat{\gamma}_i^{(1)})} = 195$$

$$\hat{\pi}^{(2)} = 0.5$$



Distributions à la fin de l'itération 2

## Itération 12

---


$$\hat{\mu}_1^{(2)} = \frac{\sum_{i=1}^N (1 - \hat{\gamma}_i^{(1)}) y_i}{\sum_{i=1}^N (1 - \hat{\gamma}_i^{(1)})} = 222$$

$$\hat{\mu}_2^{(2)} = \frac{\sum_{i=1}^N (\hat{\gamma}_i^{(1)}) y_i}{\sum_{i=1}^N (\hat{\gamma}_i^{(1)})} = 254$$

$$\hat{\sigma}_1^{2(1)} = \frac{\sum_{i=1}^N (1 - \hat{\gamma}_i^{(1)}) (y_i - \hat{\mu}_1^{(2)})^2}{\sum_{i=1}^N (1 - \hat{\gamma}_i^{(1)})} = 104$$

$$\hat{\sigma}_2^{2(2)} = \frac{\sum_{i=1}^N (\hat{\gamma}_i^{(1)}) (y_i - \hat{\mu}_2^{(2)})^2}{\sum_{i=1}^N (\hat{\gamma}_i^{(1)})} = 86$$

$$\hat{\pi}^{(2)} = 0.5$$



Distributions à la fin de l'itération 12

- La vraisemblance augmente nécessairement à chaque itération
- Pour éviter un maximum local, il est préférable de refaire l'estimation avec divers ensembles de valeurs de départ

- L'algorithme EM permet d'estimer la distribution des densités d'un modèle de mélange de densités.

Dempster, Arthur P, Nan M Laird, and Donald B Rubin.  
1977. "Maximum Likelihood from Incomplete Data via the Em Algorithm." *Journal of the Royal Statistical Society: Series B (Methodological)* 39 (1): 1–22.

Hastie, Trevor, Robert Tibshirani, and Jerome Friedman.  
2009. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer Science & Business Media.