#### Introduction aux modèles prédictifs

Cas continu

Véronique Tremblay

Cette capsule sert de soutien à la lecture du chapitre 2 de Hastie, Tibshirani, and Friedman (2009).

Qu'est-ce qu'on cherche à faire?

# De façon générale...

On veut prédire Y à partir de X.



©Véronique Tremblay 2021 3

# Plus précisément

On cherche à estimer f(X) la fonction qui relie  ${\sf X}$  et  ${\sf Y}$ .

$$Y = f(X) + \epsilon$$



#### Fonction de perte

La fonction de perte (L) est une mesure de l'écart par rapport à ce qu'on souhaite mesurer

Par exemple, dans le cas continu, on peut utliser la fonction de perte quadratique.

$$L(Y,f(X))=(Y-f(X))^2 \\$$



#### Fonction de risque

La fonction de risque est ce que l'on cherche à minimiser. En général, il s'agit de l'espérance de la fonction de perte.

Par exemple, pour la fonction de perte quadratique, on cherche  $\hat{f}(X)$  qui minimise:

$$\mathrm{EPE}(f) = \mathbb{E}(Y - f(X))^2$$


# Comment?

## Les k plus proches voisins

En conditionnant sur X, on constate que l'on minimise  $\mbox{EPE}(f)$  avec

$$f(x) = \mathbb{E}(Y|X=x)$$





## Une autre approche


Supposer une certaine forme pour f(X) et minimiser la fonction de perte de façon analytique ou numérique.

## La régression linéaire simple

Par exemple, poser  $f(X)=\beta_0+\beta_1 X$  et trouver les valeurs de  $\beta_0$  et  $\beta_1$  qui minimisent

$$\mathbb{E}(Y-(\beta_0+\beta_1X))^2$$





#### Résumé

- On veut trouver la fonction qui relie X et Y
- lack II y a plusieurs façons de trouver f(X)
- Dans les prochaines capsules, nous allons voir:
  - lacktriangle Certaines façons d'estimer f(X)
  - Le compromis biais-variance
  - Comment évaluer la performance de notre modèle

©Véronique Tremblay 2021 10

#### Références

Lire le chapitre 2 de:

Hastie, Trevor, Robert Tibshirani, and Jerome Friedman. 2009. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer Science & Business Media.

©Véronique Tremblay 2021